Simulation stochastique et pricing

Des équations différentielles aux réseaux de neurones

Euler–Maruyama, Monte Carlo et modèles de substitution

Hajar Belhafid

ENSA Agadir – Finance et Ingénierie Décisionnelle

Projet académique – Année universitaire 2025–2026

Résumé

Ce projet explore les méthodes numériques de la finance quantitative, de la **discrétisation des équations différentielles stochastiques** à la **valorisation d'options européennes**. Il associe analyse de convergence, réduction de variance, estimation des sensibilités et apprentissage d'une fonction de pricing par un **réseau de neurones de substitution**. Une application Flask permet de comparer les méthodes et de visualiser les résultats. L'étude s'appuie sur les travaux de **B. Jourdain** pour les méthodes de Monte Carlo et de **M. Ludkovski** pour l'apprentissage automatique en finance quantitative.

1 Objectif et cadre de l'étude

Comprendre et comparer les sources d'erreur d'un calcul numérique : approximation des trajectoires, erreur statistique Monte Carlo et erreur d'approximation d'un modèle appris.

Deux cadres sont étudiés : le **processus d'Ornstein–Uhlenbeck**, lié au modèle de taux de Vasicek, et le **modèle de Black–Scholes**, utilisé comme référence pour les options européennes.

Discrétisation d'une EDS

Pour $dX_t = b(X_t)\,dt + \sigma(X_t)\,dW_t$, le schéma d'Euler–Maruyama s'écrit :

$$\bar{X}_{k+1} = \bar{X}_k + b(\bar{X}_k)\Delta t + \sigma(\bar{X}_k)\Delta W_k.$$

Les solutions exactes disponibles servent de références pour étudier les erreurs.

2 Convergence et valorisation

2.1 Analyse des erreurs

Comparaison des trajectoires exactes et discrétisées, étude des **erreurs forte et faible** et représentation des erreurs en échelle logarithmique. L'**extrapolation de Richardson–Romberg** est étudiée pour réduire le biais de discrétisation, sous les hypothèses de régularité appropriées.

2.2 Pricing et réduction de variance

Estimation du prix d'un call par moyenne des payoffs actualisés et comparaison à la formule de Black–Scholes. Trois techniques sont implémentées :

- variables antithétiques ;
- variable de contrôle ;
- échantillonnage préférentiel.

La variable de contrôle utilisée est le **sous-jacent actualisé** $Y = e^{-rT}S_T$, dont l'espérance risque-neutre vaut S_0. Le payoff actualisé est corrigé à l'aide d'un coefficient estimé par covariance.

3 Sensibilités et apprentissage

3.1 Estimation du Delta et du Gamma

Comparaison aux sensibilités analytiques de Black–Scholes. Pour le Delta, étude des **différences finies**, de la méthode **pathwise** et du **rapport de vraisemblance**. Le Gamma est également estimé par différences finies.

3.2 Réseau de neurones de substitution

Implémentation en **NumPy** d'un réseau dense d'architecture $3 \to 64 \to 64 \to 1$, avec activations ReLU et rétropropagation par mini-lots.

Les entrées sont $(S_0/100, K/100, \sigma)$ et les cibles sont les **prix exacts Black–Scholes**, avec $r = 5\,\%$ et $T = 1$. L'évaluation sur un jeu de test distinct utilise la RMSE et le coefficient R^2.

4 Réalisations et illustrations

Modules développés

- Simulation d'Ornstein–Uhlenbeck et analyse de convergence.
- Pricing Monte Carlo et comparaison des techniques de réduction de variance.
- Estimation des sensibilités.
- Entraînement et évaluation du réseau de substitution.
- Interface Flask et visualisations Matplotlib.

Le rapport présente, pour le processus OU, des pentes empiriques d'environ $-0{,}98$ pour l'erreur forte, $-1{,}01$ pour l'erreur faible et $-1{,}97$ après extrapolation. Ces résultats sont propres aux expériences et aux paramètres présentés dans le rapport.

5 Apports du projet

Articulation de l'analyse numérique, des probabilités et de l'apprentissage pour comparer précision et coût de calcul. Les performances dépendent du modèle, des paramètres et du domaine d'entraînement.

Outils : Python, NumPy, SciPy, Matplotlib et Flask.

6 Références scientifiques

B. Jourdain, *Méthodes de Monte Carlo pour les processus financiers*, ENPC, 2014 : discrétisation des EDS, convergence et simulation.

M. Ludkovski, *Statistical ML for Quantitative Finance*, 2023 : apprentissage automatique et modèles de substitution.

Démonstration vidéo

Voir la démonstration du projet